

INSTITUTO TECNOLÓGICO NACIONAL DE MÉXICO

CAMPUS SAN JUAN DEL RÍO, QUERÉTARO

— INTELIGENCIA ARTIFICIAL —

LÍNEA DEL TIEMPO: HISTORIA DE LA INTELIGENCIA ARTIFICIAL

— ING. LEONARDO VALDES ARTEAGA —

INTEGRANTES

CRUZ RAMIREZ JOSE PEDRO
LOMA NAVARRETE LUIS FERNANDO
ROMERO PAULIN ANGEL ELIAS

1943 – 2026

EVOLUCIÓN HISTÓRICA DE LA IA

1943-1956

Los fundamentos: neuronas, inteligencia y un nuevo campo


De una abstracción matemática del cerebro a la pregunta de si una máquina puede comportarse inteligentemente.

1943

REDES NEURONALES

McCulloch-Pitts

Warren McCulloch y Walter Pitts proponen un modelo matemático de neurona artificial, suma ponderada de entradas y un umbral de disparo.




1950

INTELIGENCIA

Prueba de Turing

Alan Turing plantea una prueba para evaluar si el comportamiento de una máquina puede ser indistinguible del de un ser humano.



1956

NACIMIENTO DE LA IA

Conferencia de Dartmouth

John McCarthy impulsa el uso del término "Inteligencia Artificial" y el área se consolida como una disciplina propia, diferenciada de la Cibernética.



IDEA CENTRAL

Representar procesos inteligentes con estructuras computables.

1943

1950

1956

1958-1969

El perceptrón, los sistemas expertos y el choque con los límites


La primera gran ola neuronal demuestra potencial, pero también deja claro qué problemas no puede resolver una sola capa.

1958

REDES NEURONALES

Perceptrón de Frank Rosenblatt

Primer modelo de red neuronal de una sola capa, inspirado en la biología. Usa una rejilla de 20x20 fotocélulas y aprende ajustando pesos mediante una regla de corrección del error.




1967

SISTEMAS EXPERTOS

DENDRAL

Uno de los primeros sistemas expertos, orientado a la química orgánica. Analiza datos de espectrometría de masas para inferir estructuras moleculares, demostrando el potencial de la IA en dominios especializados.




1969

LÍMITES DE LA IA

"Perceptrons" – Minsky & Papert

Demuestran que el perceptrón de una sola capa solo puede resolver funciones linealmente separables (como AND, OR), pero falla en problemas como XOR. Esto marca el inicio del primer invierno de la IA.



IDEA CENTRAL

El entusiasmo inicial revela tanto el potencial de la IA como la necesidad de nuevos enfoques.

1958

1967

1969

1969-1987

Invierno, retropropagación y regreso de las redes multicapa

Cuando una arquitectura no basta, el campo cambia de método: más capas, ajuste de errores y una nueva lectura de la complejidad.

1969-1985

CRISIS

Primer Invierno de la IA

El entusiasmo inicial se enfría por resultados limitados, expectativas desbordadas y recortes de financiación. Los modelos de una sola capa (como el perceptrón) muestran límites matemáticos, generando decepción.




1986

RENACIMIENTO

Backpropagation

Rumelhart, McClelland y otros formalizan la retropropagación del error (backpropagation), una técnica eficiente para entrenar redes multicapa y superar el límite práctico de una sola capa.




1987

NUEVA OLA

Complejidad y NIPS

Las redes neuronales vuelven a ganar protagonismo como clasificadores no lineales universales. La conferencia NIPS (Neural Information Processing Systems) se consolida y la ciencia de la complejidad impulsa nuevas conexiones.



IDEA CENTRAL

Los “inviernos” no son solo falta de dinero, sino crisis de expectativas.

Cuando la teoría, el hardware y las expectativas no se alinean, el entusiasmo se enfría. La recuperación llega con nuevas ideas, mejores métodos y una visión más realista.



1986

1988–2009

De los laboratorios al mundo real: conducir, jugar y aprender de datos masivos

Las redes neuronales reaparecen en tareas concretas, mientras el cómputo y la disponibilidad de datos se vuelven factores decisivos.

1988–1989

ALVINN

Carnegie Mellon desarrolla un vehículo autónomo con una red de 3 capas (entrada 30×32, capa oculta y salida de dirección) entrenada con backpropagation.



1990s

Segundo Invierno

El entusiasmo se enfría por la falta de cómputo, la escasez de datos y expectativas demasiado altas. El desarrollo de redes neuronales se ralentiza durante casi una década.



1997

Deep Blue

IBM derrota a Garry Kasparov y marca un hito de capacidad computacional aplicada al ajedrez, mostrando el poder de buscar y evaluar millones de posiciones.



2006–2009

ImageNet – Fei-Fei Li

Base de datos con más de 1.2 millones de imágenes etiquetadas. La escala de los datos se convierte en parte central del problema de aprendizaje.




TRES CAMBIOS DE ESCALA



ALVINN



Deep Blue



ImageNet

Modelo → Cómputo → Datos

La siguiente explosión del campo llegará cuando estos tres componentes vuelvan a crecer juntos.

1988–1989

1990s

1997

2006–2009

La revolución del Deep Learning: AlexNet, GPUs y redes mucho más profundas


La combinación de datos, paralelismo y nuevas arquitecturas cambia la velocidad con la que las redes pueden aprender.

2012

GPU + CNN

AlexNet

Krizhevsky, Sutskever y Hinton ganan ImageNet con una CNN de 8 capas y ~60 millones de parámetros. El trabajo demostró el poder de las GPUs para entrenar redes profundas y marcó el inicio del renacimiento del Deep Learning.



2015

PROFUNDIDAD

ResNet


Las redes residuales (ResNet) superan las 100 capas. En el material se reporta un error de 3.6% en ImageNet, señalando el salto hacia modelos mucho más profundos gracias a las conexiones residuales.



GPUs: CÓMPUTO EN PARALELO



PROFUNDIDAD + CONEXIONES RESIDUALES



2020-2022

La escala se vuelve generativa

Los modelos dejan de ser solo clasificadores: escriben, predicen estructuras, generan imágenes y empiezan a colaborar con humanos.

2020

GPT-3 + AlphaFold 2

GPT-3 lleva el escalado de modelos de lenguaje a 175 mil millones de parámetros. AlphaFold 2 aplica IA a la predicción de estructuras 3D de proteínas.



La IA puede ayudar a las personas a pensar, crear y resolver problemas...



AlphaFold 2
Predicción de proteínas

2021

Multimodalidad

DALL·E genera imágenes desde texto; CLIP conecta lenguaje e imagen. GitHub Copilot, apoyado en Codex, populariza la programación asistida por IA.

"Un astronauta montando un caballo en Marte"



Imagen desde texto



Código asistido



Audio




Video

2022

ChatGPT y arte generativo

Midjourney y Stable Diffusion impulsan la generación de imágenes. El 30 de noviembre OpenAI lanza ChatGPT, basado en GPT-3.5 y RLHF; el material destaca su rápida adopción.



¿Qué idea te gustaría explorar hoy?

Crea una imagen de una ciudad futurista al atardecer.

Enviar un mensaje...



UNA MISMA TENDENCIA

TXT

lenguaje

IMG

imagen

BIO

proteínas

</>

código

CHAT

diálogo

Modelos generales capaces de trabajar con más tipos de contenido.

2022

2023-2024

Multimodalidad nativa, copilotos y agentes

La IA pasa del modelo aislado a sistemas integrados con software, herramientas y flujos de trabajo.

2023

ECOSISTEMA

Guerra de gigantes y modelos multimodales

El material destaca GPT-4; la integración de Copilot en productos de Microsoft; la unión de Google Brain y DeepMind; Gemini; y LLaMA como impulso a los modelos open-weight.



2024

AGENTES

Video generativo y transición a agentes

Sora simboliza el salto del texto a video. También se describe la transición de chatbots a agentes capaces de planificar, ejecutar código y operar herramientas. El costo energético y el uso de agua en centros de datos aparecen como nuevos cuellos de botella.



DE CHATBOT A AGENTE

- 1 **Planifica**
Define objetivos y descompone tareas.
- 2 **Usa herramientas**
Accede a software, APIs y datos.
- 3 **Ejecuta**
Realiza acciones de forma autónoma.
- 4 **Verifica**
Evalúa resultados y se ajusta.

Nuevo límite: energía e infraestructura

2024

Razonamiento avanzado, chips propios y cómputo en memoria

La siguiente frontera del material no es solo hacer modelos mayores, sino volverlos más eficientes, integrados y capaces de razonar antes de responder.

2025-2026

Modelos de razonamiento

Se consolidan modelos que priorizan deducción paso a paso y verificación lógica antes de responder, como la serie "o" de OpenAI y equivalentes de la industria.



2025-2026

Aceleradores personalizados

El material señala una menor dependencia exclusiva de NVIDIA mediante TPUs y chips propios de grandes compañías tecnológicas, optimizados para modelos de razonamiento y mayor eficiencia energética.




Vanguardia

Computing-in-Memory

Redes neuronales analógicas, como las asociadas a Mythic, usan celdas NOR Flash como resistores variables para multiplicación matricial analógica y buscan reducir el cuello de botella de Von Neumann.



MATRIZ ANALÓGICA



Cálculo dentro de la memoria

Meta: menos movimiento de datos y mejor eficiencia energética.

REFERENCIAS

Formato APA 7.^a edición

- 01 • McCulloch, W. S., & Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, 5, 115–133.
- 02 • Turing, A. M. (1950). Computing machinery and intelligence. *Mind*, 59(236), 433–460.
- 03 • Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408.
- 04 • Minsky, M., & Papert, S. (1969). *Perceptrons: An introduction to computational geometry*. MIT Press.
- 05 • Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25, 1097–1105.
- 06 • He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770–778.
- 07 • OpenAI. (2022, November 30). *Introducing ChatGPT*. <https://openai.com/blog/chatgpt>
- 08 • BBVA. (s. f.). *Historia de la inteligencia artificial*. <https://www.bbva.com/es/innovacion/historia-de-la-inteligencia-artificial/>
- 09 • El Hacker.net. (2026, abril). *Ada Lovelace anticipó los límites de la inteligencia artificial*. <https://blog.elhacker.net/2026/04/ada-lovelace-anticipo-los-limites-de-la.html>